

Embeddings e Busca Semântica

1. Introdução

Com o crescimento da quantidade de informações disponíveis em formato digital, tornou-se necessário desenvolver técnicas capazes de representar textos de maneira que computadores possam compreendê-los e processá-los de forma eficiente. Uma das tecnologias mais importantes para isso são os embeddings.

Embeddings são representações numéricas de palavras, frases ou documentos em um espaço vetorial. Essas representações permitem que algoritmos identifiquem relações semânticas entre diferentes textos, mesmo quando eles não possuem exatamente as mesmas palavras.

Atualmente, embeddings são utilizados em diversas aplicações de Inteligência Artificial, incluindo mecanismos de busca, sistemas de recomendação, chatbots, assistentes virtuais e sistemas baseados em Retrieval-Augmented Generation (RAG).

2. O Problema da Representação de Texto

Computadores trabalham naturalmente com números. Entretanto, textos são compostos por palavras e símbolos, o que dificulta seu processamento direto.

Antes do surgimento dos embeddings, uma das técnicas mais utilizadas era o One-Hot Encoding.

Nessa abordagem, cada palavra era representada por um vetor contendo apenas um valor igual a 1 e todos os demais valores iguais a 0.

Exemplo simplificado:

Vocabulário:

- gato
- cachorro
- avião

Representações:

- gato $\rightarrow [1, 0, 0]$
- cachorro $\rightarrow [0, 1, 0]$
- avião $\rightarrow [0, 0, 1]$

Embora simples, essa abordagem apresenta limitações importantes:

- gera vetores muito grandes;
- não captura significado;
- não representa similaridade entre palavras.

Para o computador, "gato" e "cachorro" são tão diferentes quanto "gato" e "avião".

3. O que são Embeddings?

Embeddings surgiram como uma solução para representar significado de forma matemática.

Um embedding é um vetor numérico que procura capturar características semânticas de uma palavra, frase ou documento.

Exemplo:

Palavra:

gato

Embedding:

[0.42, -0.15, 0.88, 0.34, ...]

Palavra:

cachorro

Embedding:

[0.39, -0.12, 0.85, 0.31, ...]

Como os significados são parecidos, seus vetores tendem a ficar próximos no espaço vetorial.

Já palavras com significados muito diferentes tendem a ficar mais distantes.

Essa propriedade permite que algoritmos comparem significados utilizando operações matemáticas.

4. Similaridade Semântica

Uma das características mais importantes dos embeddings é a capacidade de medir similaridade semântica.

Textos com significados parecidos costumam possuir embeddings próximos.

Exemplos:

- médico ↔ hospital
- professor ↔ escola
- cachorro ↔ gato

Por outro lado:

- cachorro ↔ avião
- médico ↔ futebol

tendem a apresentar menor proximidade.

Essa comparação é fundamental para sistemas modernos de recuperação de informação.

5. Distância Cosseno

Para medir a proximidade entre embeddings, uma das métricas mais utilizadas é a Similaridade do Cosseno.

Essa métrica compara o ângulo entre dois vetores.

Quanto mais próximos os vetores estiverem apontando para a mesma direção, maior será a similaridade.

Valores próximos de:

- 1 → muito semelhantes
- 0 → pouca relação
- -1 → significados opostos

A Similaridade do Cosseno é amplamente utilizada em sistemas de busca semântica e recuperação vetorial.

6. Como os Embeddings São Gerados?

Diversos métodos foram desenvolvidos para gerar embeddings.

Word2Vec

O Word2Vec foi uma das primeiras técnicas amplamente utilizadas.

Seu objetivo era aprender representações vetoriais analisando o contexto em que as palavras aparecem.

A ideia central é que palavras utilizadas em contextos semelhantes tendem a possuir significados semelhantes.

GloVe

O GloVe (Global Vectors for Word Representation) combina estatísticas globais do corpus com aprendizado vetorial.

Essa abordagem permite capturar relações semânticas de forma eficiente.

FastText

O FastText representa palavras utilizando partes menores chamadas subpalavras.

Isso ajuda a lidar melhor com palavras raras ou desconhecidas.

Embeddings Modernos

Atualmente, modelos como BERT, Gemma, GPT e Llama geram embeddings contextualizados.

Isso significa que uma mesma palavra pode possuir representações diferentes dependendo do contexto em que aparece.

Exemplo:

- banco (instituição financeira)
- banco (assento)

O modelo consegue diferenciar os significados de acordo com a frase.

7. Busca Semântica

A Busca Semântica é uma das aplicações mais importantes dos embeddings.

Nos mecanismos tradicionais, a recuperação depende principalmente de palavras-chave.

Exemplo:

Consulta:

"como armazenar vetores"

Documento:

"armazenamento de embeddings"

Mesmo tratando do mesmo assunto, um sistema baseado apenas em palavras-chave pode não recuperar o documento.

Com embeddings, a recuperação ocorre pelo significado da consulta.

Isso permite resultados muito mais relevantes.

8. Embeddings em Sistemas RAG

Sistemas RAG (Retrieval-Augmented Generation) utilizam embeddings em praticamente todas as etapas de recuperação.

O processo normalmente ocorre da seguinte forma:

1. Os documentos são divididos em chunks.
2. Cada chunk recebe um embedding.
3. Os embeddings são armazenados.
4. A pergunta do usuário também é transformada em embedding.
5. O sistema busca os vetores mais próximos.
6. Os trechos recuperados são enviados para a LLM.

Graças aos embeddings, a recuperação ocorre por significado e não apenas por palavras exatas.

9. Aplicações dos Embeddings

Os embeddings possuem aplicações em diversas áreas.

Sistemas de Busca

Permitem encontrar documentos relacionados ao significado da consulta.

Chatbots

Melhoram a compreensão das perguntas dos usuários.

Sistemas de Recomendação

Identificam itens semelhantes com base em características compartilhadas.

Classificação de Texto

Facilitam a categorização automática de documentos.

Sistemas RAG

Permitem recuperar contexto relevante para geração de respostas.

Assistentes Virtuais

Aumentam a capacidade de compreensão da linguagem natural.

10. Vantagens dos Embeddings

Entre as principais vantagens estão:

- representação eficiente de texto;
 - captura de significado semântico;
 - redução da dimensionalidade;
 - melhor recuperação de informações;
 - maior qualidade em sistemas de recomendação;
 - suporte a aplicações modernas de IA.
-

11. Limitações dos Embeddings

Apesar das vantagens, os embeddings também possuem limitações.

Entre elas:

- dependência da qualidade dos dados de treinamento;
- possibilidade de reproduzir vieses presentes nos dados;
- custo computacional em modelos maiores;
- dificuldade de interpretação dos vetores gerados;
- perda de algumas informações contextuais em modelos mais simples.

Por esse motivo, a escolha do modelo de embedding deve considerar o problema a ser resolvido.

12. Resumo

Embeddings são representações vetoriais capazes de transformar textos em números que preservam relações semânticas.

Eles são fundamentais para aplicações modernas de Inteligência Artificial, especialmente em sistemas de busca semântica, recomendação, processamento de linguagem natural e RAG.

Ao permitir a comparação matemática entre significados, os embeddings se tornaram uma das tecnologias mais importantes para o desenvolvimento de sistemas inteligentes capazes de compreender linguagem humana.