

Retrieval-Augmented Generation (RAG) e Bases Vetoriais

1. Introdução

Os Modelos de Linguagem de Grande Porte (LLMs), como Gemma, GPT e Llama, revolucionaram a forma como sistemas computacionais interagem com seres humanos. Esses modelos são capazes de gerar textos coerentes, responder perguntas e auxiliar em diversas tarefas cognitivas.

Apesar de seu grande potencial, esses modelos apresentam uma limitação importante: eles não possuem acesso automático a informações atualizadas ou específicas de um determinado contexto. Como resultado, podem gerar respostas incorretas ou inventar informações inexistentes, fenômeno conhecido como alucinação.

Para reduzir esse problema surgiu a técnica chamada Retrieval-Augmented Generation (RAG), que combina recuperação de informações com geração de texto. O objetivo é fornecer contexto relevante para a LLM antes da geração da resposta, tornando as respostas mais confiáveis e fundamentadas.

2. O Problema das Alucinações em LLMs

Uma alucinação ocorre quando um modelo de linguagem produz uma informação que parece correta, mas não possui base real ou não está presente em nenhuma fonte confiável.

Exemplo:

Pergunta:

"Qual foi a nota do aluno João na prova de IA?"

Se o modelo não possuir essa informação, ele pode gerar uma resposta inventada.

Isso ocorre porque os modelos de linguagem são treinados para prever a próxima palavra mais provável e não para verificar fatos em tempo real.

As principais causas das alucinações incluem:

- ausência de contexto específico;
- informações desatualizadas;
- limitações do conjunto de treinamento;
- ambiguidades na pergunta do usuário.

O RAG foi desenvolvido justamente para reduzir esse tipo de problema.

3. O que é Retrieval-Augmented Generation?

Retrieval-Augmented Generation, ou simplesmente RAG, é uma arquitetura que combina dois processos:

Recuperação (Retrieval)

Busca informações relevantes em uma base de documentos.

Geração (Generation)

Utiliza os documentos recuperados como contexto para gerar uma resposta.

Em vez de depender apenas do conhecimento armazenado durante o treinamento da LLM, o sistema passa a consultar fontes externas antes de responder.

Isso permite que a resposta seja baseada em informações reais presentes nos documentos disponíveis.

4. Como o RAG Funciona?

O funcionamento de um sistema RAG pode ser dividido em diversas etapas.

Etapas 1 – Coleta de Documentos

Inicialmente é necessário possuir uma base de conhecimento.

Esses documentos podem ser:

- PDFs;
- artigos;
- apostilas;
- páginas web;
- arquivos TXT;
- bancos de dados.

No caso do JARVIS Acadêmico, os documentos são materiais de estudo enviados pelo usuário.

Etapas 2 – Chunking

Os documentos geralmente são muito grandes para serem enviados integralmente para a LLM.

Por esse motivo, eles são divididos em pequenos trechos chamados chunks.

Exemplo:

Documento:

"Embeddings são representações numéricas de textos..."

Chunk 1:

"Embeddings são representações numéricas..."

Chunk 2:

"Eles permitem comparar significados..."

Essa divisão melhora a eficiência da recuperação.

Etapa 3 – Geração de Embeddings

Cada chunk é transformado em uma representação vetorial.

Essas representações são chamadas de embeddings.

Os embeddings permitem medir similaridade semântica entre textos.

Dessa forma, o sistema consegue localizar conteúdos relacionados ao significado da pergunta do usuário.

Etapa 4 – Armazenamento Vetorial

Os embeddings gerados são armazenados em uma estrutura apropriada para busca.

Essa estrutura é chamada de base vetorial.

Uma base vetorial não armazena apenas texto.

Ela armazena:

- conteúdo original;
- embedding correspondente;
- metadados.

Isso permite buscas rápidas mesmo em grandes quantidades de documentos.

Etapa 5 – Consulta do Usuário

Quando o usuário faz uma pergunta, o sistema também transforma essa pergunta em embedding.

Exemplo:

Pergunta:

"O que são embeddings?"

O sistema converte essa frase para um vetor numérico.

Etapa 6 – Recuperação

A consulta vetorial é comparada com os embeddings armazenados.

Os chunks mais semelhantes são selecionados.

Exemplo:

Pergunta:

"O que são embeddings?"

Chunks recuperados:

- definição de embeddings;
- aplicações dos embeddings;
- relação entre embeddings e busca semântica.

Esses trechos serão utilizados como contexto.

Etapa 7 – Geração da Resposta

Por fim, a LLM recebe:

- pergunta do usuário;
- trechos recuperados.

Com essas informações ela produz uma resposta fundamentada.

Essa resposta tende a ser mais precisa do que uma resposta gerada apenas com conhecimento interno do modelo.

5. Bases Vetoriais

As bases vetoriais são componentes fundamentais de sistemas RAG.

Seu objetivo é armazenar embeddings e permitir consultas eficientes por similaridade.

Diferentemente dos bancos de dados tradicionais, elas trabalham diretamente com vetores numéricos.

Algumas soluções populares incluem:

- FAISS
- ChromaDB
- Pinecone
- Weaviate
- Milvus

Essas ferramentas foram desenvolvidas especificamente para recuperação vetorial em aplicações de Inteligência Artificial.

6. Vantagens do RAG

O uso do RAG oferece diversos benefícios.

Redução de Alucinações

As respostas passam a ser baseadas em documentos reais.

Conhecimento Atualizado

Novos documentos podem ser adicionados sem necessidade de treinar novamente a LLM.

Maior Transparência

É possível mostrar quais documentos foram utilizados na resposta.

Especialização

O sistema pode responder perguntas sobre domínios específicos utilizando materiais próprios.

Melhor Experiência do Usuário

As respostas tornam-se mais confiáveis e contextualizadas.

7. Limitações do RAG

Apesar de suas vantagens, o RAG não elimina todos os problemas.

Entre suas limitações estão:

Dependência da Recuperação

Se os documentos corretos não forem recuperados, a resposta poderá ser inadequada.

Qualidade dos Documentos

Documentos incompletos ou incorretos prejudicam os resultados.

Custo Computacional

A geração de embeddings e as consultas vetoriais exigem recursos computacionais adicionais.

Erros de Similaridade

Em alguns casos, documentos semanticamente parecidos podem ser recuperados mesmo não sendo os mais adequados.

8. Aplicações do RAG

A arquitetura RAG pode ser utilizada em diversos cenários.

Assistentes Acadêmicos

Permitem responder perguntas utilizando materiais de estudo.

Chatbots Corporativos

Consultam documentos internos da empresa.

Sistemas Jurídicos

Buscam leis, normas e decisões anteriores.

Sistemas Médicos

Recuperam informações clínicas relevantes.

Plataformas Educacionais

Fornecem respostas baseadas em apostilas e conteúdos didáticos.

9. O RAG no Projeto JARVIS Acadêmico

No projeto JARVIS Acadêmico, o RAG é responsável pela funcionalidade de consulta a materiais de estudo.

O fluxo utilizado é:

1. Carregamento dos documentos.
2. Divisão em chunks.
3. Geração de embeddings.
4. Recuperação dos trechos mais relevantes.
5. Envio dos trechos para a LLM.
6. Geração da resposta final.

Além disso, o RAG também é utilizado para:

- geração de exercícios;
- avaliação de respostas;
- planejamento de estudos.

Dessa forma, o sistema consegue utilizar os materiais enviados pelo usuário como fonte principal de conhecimento.

10. Resumo

Retrieval-Augmented Generation (RAG) é uma técnica que combina recuperação de informações e geração de texto.

Seu principal objetivo é fornecer contexto relevante para modelos de linguagem, reduzindo alucinações e aumentando a confiabilidade das respostas.

O processo envolve chunking, geração de embeddings, armazenamento em bases vetoriais, recuperação de trechos relevantes e geração da resposta final.

Atualmente, o RAG é uma das arquiteturas mais utilizadas em aplicações modernas de Inteligência Artificial, especialmente em assistentes inteligentes, sistemas educacionais e plataformas corporativas.